

大模型+强化学习因子挖掘

华泰研究

2025 年 12 月 04 日 | 中国内地

深度研究

人工智能 97：大模型+强化学习挖掘量价因子

本文基于大模型+强化学习技术，探索二者结合在因子挖掘场景下的应用潜力。通过对因子表达式的 Token 化建模，强化学习可在指定环境中以 Token 单元组成动作序列，形成完整的 Alpha 因子表达式；大模型则可借助其金融领域知识为强化学习去芜存菁，注入活水，有效提升强化学习因子挖掘的效果及稳定性。基于该框架产出因子构建沪深 300 指增策略，回测区间（20201231-20251128）策略年化超额 17.85%，信息比率 1.50；中证 500 指增策略年化超额收益率 9.78%，信息比率 0.67。

强化学习应用于因子挖掘：Token 化序列建模与序列决策

Token 化是强化学习因子挖掘框架的根基。其目标是将任何数学表达式映射为一个可学习、可生成的离散序列，使强化学习模型能在离散空间中高效操作。完成 Token 化之后，因子挖掘问题便可以转化为一个序列决策问题，即每一步从有限 Token 集中选取一个符号，将其加入表达式序列中，直到构造完成一个可执行的因子表达式。强化学习正是解决这类问题的标准方法。其核心思想在于，让模型在“试错”中学习如何生成更优质的表达式，通过奖励机制不断向高质量因子空间逼近。

强化学习的因子挖掘短板与大模型的知识注入

在实际进行强化学习因子挖掘时，我们会发现强化学习模型产出的相当一部分因子存在构造简单、不合逻辑、符号多余等问题，原因在于强化学习模型并不具备语义理解能力，难以构造符合逻辑、具备一定经济学含义的因子，而这恰恰是大模型的优势所在。因此在本文框架中，我们尝试融入大模型的领域知识，一方面是构造基础池，即为强化学习模型提供一个“热身”过程，可能更容易挖掘出效果更进一步的因子；另一方面是定期注入新因子，剔除劣质因子，避免强化学习模型陷入局部最优。

大模型+强化学习因子挖掘全流程

在因子挖掘流程中，由基于 MaskablePPO 算法的强化学习模型持续不断生成 Token，以实现因子的不断挖掘。模型交互的环境可称之为 AlphaPool，对应特定股票池的 Alpha 因子池。对于模型生成的任意因子，由 AlphaPool 完成评估，例如 IC 计算、是否为之前的失败缓存因子、能否入池等等，基于评估结果确定反馈给强化学习模型的奖励水平。在此之外，开始挖掘前，大模型可生成一定数量因子作为初始因子池，强化学习后续迭代过程中，大模型亦会定期注入新因子以替换劣质因子。

强化学习因子挖掘效果较优，大模型增益效果明显

基于强化学习挖掘出的因子组合在沪深 300 指增策略表现优异，回测区间内年化超额收益率可达 16.41%；在中证 500 指增策略中表现同样较好，回测区间内年化超额收益率达 7.17%。大模型提供初始因子池，同时定期更新因子池后，回测区间内，对于沪深 300 指增组合，策略年化超额出现明显提升，由 16.41%提升至 17.85%，信息比率从 1.28 提升至 1.50；中证 500 指增策略表现类似，年化超额收益率提升由 7.17%提升至 9.78%，信息比率从 0.48 提升至 0.67。

风险提示：大模型是海量数据训练获得的产物，输出准确性及稳定性可能存在风险；不同大模型效果存在差异，需谨慎选择；非本地大模型处理敏感数据或有信息泄露风险；通过强化学习模型构建选股策略是历史经验的总结，存在失效的可能。强化学习模型可解释程度较低，使用须谨慎。

沈洋*

研究员


SAC No. S0570525070013 shenyang023029@htsc.com
+(86) 21 2897 2202

何康, PhD

研究员


SAC No. S0570520080004 hegang@htsc.com
SFC No. BRB318 +(86) 21 2897 2202

强化学习因子挖掘指增策略累计超额



资料来源：Wind，华泰研究

大模型增强后的指增策略累计超额



资料来源：Wind，华泰研究

正文目录

导言	5
“因子挖掘机”：大模型+强化学习因子挖掘	6
因子表达式的 Token 化序列建模	6
强化学习与因子挖掘	6
公式化 Alpha 与强化学习：为什么 RL 合适？	6
因子挖掘如何构建 RL 环境？	7
强化学习+因子挖掘全流程	7
因子挖掘中的强化学习算法：PPO	8
大模型与因子挖掘	10
方法	11
强化学习挖掘因子流程	11
因子挖掘字段、常数、算符设置	11
奖励设置	12
因子组合权重训练模型	13
强化学习神经网络模型	13
大模型的角色	14
超参数设置	14
结果	16
初始测试	16
LSTM 与 Transformer 效果对比	17
IC Pool 与 ICIR Pool 效果对比	19
因子复杂度约束效果对比	19
奖励设置效果对比	20
长训练观察	21
因子数量效果对比	23
大模型增强效果	23
因子泛化性测试	25
因子评估与因子相关性	27
指增策略收紧约束效果	29
总结	31
参考文献	31
风险提示	31

图表目录

图表 1：Alpha 因子表达形式对比图	6
图表 2：强化学习 Agent 与环境交互示意图	7

图表 3: Actor-Critic 架构	8
图表 4: PPO 算法的演进	9
图表 5: PPO 算法伪代码	9
图表 6: GPT 因子工厂示意图	10
图表 7: 强化学习因子挖掘示意图	11
图表 8: 因子挖掘使用的字段列表	11
图表 9: 因子挖掘使用的常数列表	11
图表 10: 因子挖掘使用的算子列表	12
图表 11: 强化学习因子挖掘奖励设计图	12
图表 12: AlphaPool 环境与因子权重优化流程	13
图表 13: 强化学习策略模型参数优化流程	14
图表 14: 大模型参与强化学习因子挖掘流程图	14
图表 15: 大模型+强化学习超参数设置	15
图表 16: 初始测试超参数设置	16
图表 17: 沪深 300 指增策略参数	16
图表 18: 初始测试沪深 300 指增策略效果（累计超额）	17
图表 19: 初始测试沪深 300 指增策略效果（业绩指标）	17
图表 20: LSTM 与 Transformer 效果对比超参数设置	17
图表 21: LSTM 与 Transformer 的沪深 300 指增策略效果对比（累计超额）	18
图表 22: LSTM 与 Transformer 的沪深 300 指增策略效果对比（业绩指标）	18
图表 23: LSTM 与 Transformer 的中证 500 指增策略效果对比（累计超额）	18
图表 24: LSTM 与 Transformer 的中证 500 指增策略效果对比（业绩指标）	19
图表 25: IC Pool 与 ICIR Pool 的沪深 300 指增策略效果对比（累计超额）	19
图表 26: IC Pool 与 ICIR Pool 的沪深 300 指增策略效果对比（业绩指标）	19
图表 27: 不同因子复杂度的沪深 300 指增策略效果对比（累计超额）	20
图表 28: 不同因子复杂度的沪深 300 指增策略效果对比（业绩指标）	20
图表 29: 不同奖励设置	20
图表 30: 不同奖励设置下的沪深 300 指增策略效果对比（累计超额）	21
图表 31: 不同奖励设置下的沪深 300 指增策略效果对比（业绩指标）	21
图表 32: 长训练下不同 step 的沪深 300 指增策略效果对比（累计超额）	22
图表 33: 长训练下不同 step 的沪深 300 指增策略效果对比（业绩指标）	22
图表 34: 长训练中不同数据集表现随训练步数变化	22
图表 35: 不同因子数量下的沪深 300 指增策略效果对比（累计超额）	23
图表 36: 不同因子数量下的沪深 300 指增策略效果对比（业绩指标）	23
图表 37: RL 与 RL+大模型的沪深 300 指增策略效果对比（累计超额）	24
图表 38: RL 与 RL+大模型的沪深 300 指增策略效果对比（业绩指标）	24
图表 39: RL 的沪深 300 指增策略逐月超额收益	24
图表 40: RL+大模型的沪深 300 指增策略逐月超额收益	24
图表 41: RL 与 RL+大模型的中证 500 指增策略效果对比（累计超额）	25
图表 42: RL 与 RL+大模型的中证 500 指增策略效果对比（业绩指标）	25



图表 43: RL 的中证 500 指增策略逐月超额收益.....	25
图表 44: RL+大模型的中证 500 指增策略逐月超额收益.....	25
图表 45: 沪深 300 因子组合应用于中证 500 指增策略效果.....	26
图表 46: 沪深 300 因子组合应用于中证 500 指增策略效果（业绩指标）.....	26
图表 47: 沪深 300 因子组合应用于中证 500 指增策略逐月超额收益.....	26
图表 48: 中证 500 因子组合应用于沪深 300 指增策略效果.....	26
图表 49: 中证 500 因子组合应用于沪深 300 指增策略效果（业绩指标）.....	27
图表 50: 中证 500 因子组合应用于沪深 300 指增策略逐月超额收益.....	27
图表 51: 沪深 300 因子组合累计 IC 与 RankIC.....	27
图表 52: 沪深 300 因子组合累计分层超额收益.....	27
图表 53: 沪深 300 因子组合与 Barra 风险因子相关性.....	27
图表 54: 沪深 300 因子组合与 GRU 量价因子时序相关性.....	28
图表 55: 中证 500 因子组合累计 IC 与 RankIC.....	28
图表 56: 中证 500 因子组合累计分层超额收益.....	28
图表 57: 中证 500 因子组合与 Barra 风险因子相关性.....	28
图表 58: 中证 500 因子组合与 GRU 量价因子时序相关性.....	29
图表 59: 指增策略参数（收紧约束）.....	29
图表 60: 收紧约束下沪深 300 指增策略效果.....	30
图表 61: 收紧约束下沪深 300 指增策略效果（业绩指标）.....	30
图表 62: 收紧约束下中证 500 指增策略效果.....	30
图表 63: 收紧约束下中证 500 指增策略效果（业绩指标）.....	30

导言

在量化投资体系中，公式化因子因其透明性、可解释性，始终是量化模型的核心要件。然而，随着市场结构演化、特征维度骤增以及信噪比显著下降，传统依赖专家经验或简单符号回归的因子挖掘方法，难以在数以亿级的表达式空间中持续发现新的有效信号。

因子挖掘技术开始逐步转向机器学习、强化学习与大语言模型驱动的自动化因子生成框架。这些方法不再沿用预设经济假设、手工构造因子的传统流程，而是通过搜索表达式空间、自动评价、策略迭代优化的形式，让模型从历史数据中自主寻找具备预测能力的结构化 Alpha。传统上，这一自动生成公式化 Alpha 集合的框架大多基于遗传规划（Genetic Programming, GP），但遗传规划却存在诸多问题，例如对初始种群敏感、容易陷入局部最优以及计算速度慢等。

促进趋势变革的代表作是 Generating synergistic formulaic alpha collections via reinforcement learning (Yu et al., 2023)，其将因子表达式表示为 RPN（Reverse Polish Notation，逆波兰表达式）序列，通过 PPO 训练策略网络逐 token 构造因子，大幅突破了遗传规划在深度表达式搜索上的表现瓶颈。随后，Alpha² (Xu et al., 2024) 进一步将因子表达式视为“可执行程序”，融合蒙特卡洛树搜索与深度强化学习，使模型能在搜索过程中实时检查维度一致性，并对冗余或无效分支提前剪枝，显著提高因子发现效率。

与此同时，随着生成式大模型的突破，LLM 在强化学习因子挖掘体系中也可以承担特殊角色。例如在训练初期，大模型或能根据广泛的跨资产知识与金融语言模式，生成“金融含义合理、满足常识约束”的初始因子表达式，为强化学习搜索提供高质量“种子因子池”；在训练过程中，大模型或能作为“因子审查器”，帮助识别未来信息泄露、非稳态特征组合、无意义算子配对，亦可对强化学习生成的表达式进行解释，提高因子研发的透明度与可控性。

本文尝试结合大模型+强化学习，将其应用于因子挖掘场景。一方面，通过对因子表达式的 Token 化建模，强化学习可在指定环境中以 Token 单元组成动作序列，形成完整的 Alpha 因子表达式；另一方面，大模型则可借助其金融领域知识为强化学习去芜存菁，注入活水，有效提升强化学习因子挖掘的效果及稳定性。从结果上看，本文一定程度上验证了强化学习挖掘因子的可行性，以及大模型对于强化学习因子挖掘的增益效果。


“因子挖掘机”：大模型+强化学习因子挖掘

大模型+强化学习应用于因子挖掘的潜在价值，在于其突破了传统符号回归和遗传算法的诸多限制。大模型具备广泛的跨领域知识与金融语言模式，可提供初始因子池与可解释性较强的因子，而强化学习可通过序列决策的方式生成因子，使其具备在海量参数空间中有效搜索的能力。

因子表达式的 Token 化序列建模

Token 化是强化学习因子挖掘框架的根基。其目标是将任何数学表达式映射为一个可学习、可生成的离散序列，使强化学习模型能在离散空间中高效操作。逆波兰表达式（Reverse Polish Notation, RPN）是 Token 化的主流方案。逆波兰表达式将表达式按后序遍历编码成一个线性 Token 序列，例如 BEG/SEP 作为序列起止指示符、Rank/TsRank/Mul 作为算子符、low 作为行情字段符。

图表1：Alpha 因子表达形式对比图



资料来源：Zhu & Zhu (2025) AlphaQCM, 华泰研究

逆波兰表达式的优势在于序列化简单、容易用 PPO 或其他强化学习算法进行序列生成。然而其同样存在明显缺点，例如表达式无法在生成过程中被解析，必须在序列结束后才能执行、无法进行实时维度检查、容易生成大量无意义表达式（如 close + volume）、强化学习奖励只能在序列结束后计算等等。

强化学习与因子挖掘

在完成 Token 化之后，因子挖掘问题便可以转化为一个序列决策问题，即每一步从有限 Token 集中选取一个符号，将其加入表达式序列中，直到构造完成一个可执行的因子表达式。强化学习（Reinforcement Learning, RL）正是解决这类问题的标准方法。其核心思想在于，让模型在“试错”中学习如何生成更优质的表达式，通过奖励机制不断向高质量因子空间逼近。关于强化学习的相关概念可参考我们的前期报告《人工智能 59：强化学习初探与 DQN 择时》（20220721）。

公式化 Alpha 与强化学习：为什么 RL 合适？

在因子挖掘中，我们希望模型能做到从极大的表达式空间中探索未知结构，能够持续发现对未来收益有预测力的因子，能够自动学习什么样的 Alpha 表达式是有价值的，尽可能在不同期限、不同市场中具备稳健性。


而强化学习的本质是在环境中不断尝试不同动作，自主学习哪些动作序列能带来更高的长期收益。这与因子挖掘的核心目标高度一致：一个 Token 代表一个动作，一个表达式代表一个决策序列、一个因子的预测能力（IC、IR、收益改善）代表奖励。强化学习的训练过程就是自主发现优秀因子表达式的过程。

因此，Shin et al. (2025) Alphaforge、Zhu & Zhu (2025) AlphaQCM 等相关研究均将因子挖掘视作强化学习问题，在因子挖掘效果上取得了显著突破。

因子挖掘如何构建 RL 环境？

要让强化学习能够在因子挖掘任务中真正发挥作用，核心在于将表达式生成过程严格形式化为一个可交互的环境（Environment）。这一过程遵循标准的马尔科夫决策过程（Markov Decision Process, MDP）框架，包括状态、动作、状态转移与奖励机制的定义。

图表2：强化学习 Agent 与环境交互示意图



资料来源：Zhu & Zhu (2025) AlphaQCM，华泰研究

在因子挖掘场景中，状态 (S_t) 可以理解为当前已生成的 Token 序列，例如“BEG → close → open → Sub → SEP”对应于表达式“close - open”的构造；动作 (A_t) 则是从候选 Token 集合中选取下一步的符号，例如算子符 (Add、Sub、Div)、行情字段符 (open、volume、high)、常数符 (0.1、5、20) 以及序列结束符 (SEP) 等。在实际实现中，随着算子与字段符的丰富，动作空间可以包含几十、上百个 Token，使得搜索空间维度呈指数级增长。每一次执行动作时，模型会将 Token 附加到已有序列中，这构成了状态转移规则。

奖励函数则是整个框架的关键，它反映了最终生成的因子是否具备预测力和实际价值。在因子挖掘中，常用的奖励指标包括 IC、Rank IC、ICIR、因子加入因子池后的收益改善 (ΔIC) 等。基于这些指标与股票数据，可评估特定表达式对应的奖励，用以激励或惩罚 RL 模型，进而不断提升生成因子的有效性、稳健性。

强化学习+因子挖掘全流程

在因子挖掘任务中，强化学习的运行方式可以直观理解为“在数学表达式空间里下棋”。当前尚未完成的表达式就像棋盘的局面，而每一步选择一个新的 Token 则相当于在棋盘上落子；当表达式最终构造完成并被回溯系统评价其 IC 或 IR 时，这个分值就成为“棋局得分”。

强化学习的目标，就是通过大量对局学习何种“落子策略”更有可能生成高质量因子。在具体实施时，策略网络会根据当前表达式结构，给出对不同 Token 的概率偏好。举例而言，当模型已生成“close - open”这样的基础价差结构时，它可能会偏向继续加入“/(high - low)”以形成价格区间的归一化，或者选择添加“ts_mean(10d)”形成动量结构等等。这种偏好并非人为设定，而是强化学习模型在反复试错中自动学习到的“金融结构规律”：哪些操作可以扩展有效的、稳定的 Alpha 结构，哪些操作在历史数据中表现无效或容易带来维度冲突。

整个学习过程由奖励信号驱动。每当生成的完整表达式获得较高 IC 或 IR，其对应的 Token 序列就会受到正向强化，从而影响策略网络在未来更倾向于采取类似路径。随着训练不断推进，模型能逐渐识别出一些通用的有效结构，例如“rank $\rightarrow$ ts_mean $\rightarrow$ ts_delta”这一类动量组合在不同市场中往往表现稳定，“(close - open) $\rightarrow$ / (high - low)”常用于价格归一化。强化学习的优势就在于，它能在极大的表达式空间中自动积累这种结构性知识，而无需人工逐一指定规则。


值得注意的是，因子挖掘中的 RL 环境具有两个潜在难点：其一是奖励相对稀疏，因为奖励通常只有在整个表达式构造完成后才会计算，这使得模型较难依靠局部反馈调整策略，通用的解决方案之一是使用 PPO 等算法构造恰当的价值评估模型，包括 Yu et al. (2023)、Zhu & Zhu (2025) AlphaQCM 等；其二是环境本身存在非平稳性，特别是当因子池动态更新时，同一表达式可能因因子池结构变化而获得不同的收益评价，导致策略学习过程不稳定。

因子挖掘中的强化学习算法：PPO

Actor-Critic 架构（AC 架构），即演员-评委架构，是一种应用极为广泛的强化学习架构。知名的 PPO、DPG、DDPG、TD3 等算法均基于 Actor-Critic 架构。其中，Actor（演员）对应于策略模型 π ，负责选择动作，直接输出策略 $\pi(a|s)$ ，即在给定状态 s 下选择动作 a 的概率分布；Critic（评委）对应于价值模型 Q ，评估 Actor 执行的动作的好坏，这可以协助 Actor 逐步优化策略模型的参数。

该架构有效融合了基于策略（Policy-Based）和基于价值（Value-Based）的方法，结合了两种方法的优势，通过同时学习策略和价值函数来提升学习效率与稳定性，是一种混合型方法。

图表3：Actor-Critic 架构




资料来源：余昌叶（2025）《大模型算法：强化学习、微调与对齐》，华泰研究

TRPO (Trust Region Policy Optimization, 置信域策略优化)，可以说是 PPO 的前身。该算法是对策略梯度算法的改进，基于两个核心概念：置信域和重要性采样 (Importance Sampling)，其主要功能是修正新旧策略之间的分布差异，使得可以利用旧策略所采集的数据来优化新策略。虽然这两个概念并非在 TRPO 中首次提出，但 TRPO 将它们与策略梯度算法相结合，显著提升了算法的效果。TRPO 的核心思想是在最大化目标函数 $J(\theta)$ 的同时，限制新旧策略之间的差异。

PPO (Proximal Policy Optimization, 近端策略优化), 有多种变体, 例如 PPO-Penalty (应用 KL 散度惩罚) 和 PPO-Clip (应用剪裁), 这些算法继承了部分 TRPO 算法的思想。PPO-Clip 因其更优的效果而获得了更多关注和应用, 因此通常所说的 PPO 即指 PPO-Clip。

图表4: PPO 算法的演进



资料来源: 余昌叶 (2025) 《大模型算法: 强化学习、微调与对齐》, 华泰研究

图表5: PPO 算法伪代码

```

1  # 简写 R:rewards, V:values, Adv:advantages, J:objective, P:probability
2  for iteration in range(num_iterations): # 进行num_iterations个训练迭代
3      # 【1/2】收集样本(prompt, response_old, logP_old, Adv, V_target)
4      prompt_batch, response_old_batch = [], []
5      logP_old_batch, Adv_batch, V_target_batch = [], [], []
6      for _ in range(num_examples):
7          logP_old, response_old = actor_model(prompt)
8          V_old = critic_model(prompt, response_old)
9          R = reward_model(prompt, response_old)[-1]
10         logP_ref = ref_model(prompt, response_old)
11
12         # KL距离惩罚。注意: 上面的R只取了最后一个token对应的奖励分数
13         KL = logP_old - logP_ref
14         R_with_KL = R - scale_factor * KL
15
16         # 通过GAE算法计算优势Adv
17         Adv = GAE_Advantage(R_with_KL, V_old, gamma, λ)
18         V_target = Adv + V_old
19
20         prompt_batch += prompt
21         response_old_batch += response_old
22         logP_old_batch += logP_old
23         Adv_batch += Adv
24         V_target_batch += V_target
25
26     # 【2/2】多轮PPO训练, 多次参数更新
27     for _ in range(ppo_epochs):
28         mini_batches = shuffle_split( (prompt_batch, response_old_batch,
29                                     logP_old_batch, Adv_batch, V_target_batch), mini_batch_size )
30
31         for prompt, response_old, logP_old, Adv, V_target in mini_batches:
32             logits, logP_new = actor_model(prompt, response_old)
33             V_new = critic_model(prompt, response_old)
34
35             # 策略概率比: ratio(θ) = π_θ(a|s) / π_θ_old(a|s)
36             ratios = exp(logP_new - logP_old)
37
38             # 计算策略模型Loss
39             L_clip = -mean( min( ratios * Adv,
40                               clip(ratios, 1 - ε, 1 + ε) * Adv ) )
41
42             S_entropy = mean( compute_entropy(logits) ) # 计算策略的熵
43
44             Loss_V = mean((V_new - V_target) ** 2) # 计算价值模型Loss
45
46             Loss = L_clip + C1 * Loss_V - C2 * S_entropy # 总损失
47             backward_update(Loss, L_clip, Loss_V) # 反向传播; 更新模型参数


```

资料来源: 余昌叶 (2025) 《大模型算法: 强化学习、微调与对齐》, 华泰研究

大模型与因子挖掘

随着以大语言模型为代表的 AI 热潮日趋演化，大语言模型与量化投资的结合也愈发紧密，一个重要的领域是基于大语言模型的因子挖掘。我们在前期研究中，尝试利用大语言模型挖掘量价因子（《人工智能 74：GPT 因子工厂：多智能体与因子挖掘》20240220）、基本面与高频因子（《人工智能 82：GPT 因子工厂 2.0：基本面与高频因子挖掘》20240926），基本验证了大语言模型在因子挖掘领域的可行性。

图表6：GPT 因子工厂示意图



资料来源：华泰研究


在本研究中，正如前文所述，虽然强化学习具备挖掘因子的各项潜在优势，但仍然难以立足于领域知识构建具备逻辑的选股因子，这或许恰恰是大模型可以融入其中的机会。我们尝试使用大语言模型增强强化学习在逻辑与可解释性方面的弱势，强强联手下，进一步提升因子挖掘体系的效果。

方法

强化学习挖掘因子流程

本文参考 Yu et al. (2023) 项目构建并优化。简单而言，在因子挖掘流程中，由 RL 模型持续不断生成 Token，以实现因子的不断挖掘。RL 模型交互的环境可称之为 AlphaPool，对应特定股票池的 Alpha 因子池。对于 RL 模型生成的任意因子，由 AlphaPool 完成评估，评估过程包括 IC 的计算、判断该因子是否为之前的失败缓存因子、判断该因子能否入池。在评估过程中，AlphaPool 可随时产生奖励并终止流程，例如因子为此前的失败缓存因子，则直接给予相应奖励结束评估，而该奖励可用于训练强化生成因子的 RL 模型。

图表7：强化学习因子挖掘示意图



资料来源：华泰研究

因子挖掘字段、常数、算符设置

本文因子挖掘主要使用股票行情相关的 6 个字段，高开低收、成交量及 VWAP。构建 alpha 公式时涉及一些常数，本文亦对其做出限制。算子方面，本文主要使用四类算子：一元操作符、二元操作符、滚动操作符和配对滚动操作符。相关设置可参考以下表格。

图表8：因子挖掘使用的字段列表

字段	含义
OPEN	开盘价
HIGH	最高价
LOW	最低价
CLOSE	收盘价
VOLUME	成交量
VWAP	成交量加权平均价

资料来源：华泰研究

图表9：因子挖掘使用的常数列表

常数
-30.0, -10.0, -5.0, -2.0, -1.0, -0.5, -0.01, 0.5, 1.0, 2.0, 5.0, 10.0, 30.0

资料来源：华泰研究

图表10：因子挖掘使用的算子列表


名称	定义	示例
一元操作符		
Abs	绝对值	Abs(\$close)
Log	对数函数	Log(\$close)
二元操作符		
Add	加法	Add(\$close, \$open)
Sub	减法	Sub(\$close, \$open)
Mul	乘法	Mul(\$close, \$volume)
Div	除法	Div(\$close, \$open)
Greater	大于比较	Greater(\$close, \$open)
Less	小于比较	Less(\$close, \$open)
滚动操作符		
Ref	引用历史值	Ref(\$close, 5)
Mean	移动平均	Mean(\$close, 20)
Sum	移动求和	Sum(\$volume, 5)
Std	标准差	Std(\$close, 20)
Var	方差	Var(\$close, 20)
Max	最大值	Max(\$close, 20)
Min	最小值	Min(\$close, 20)
Med	中位数	Med(\$close, 20)
Mad	平均绝对偏差	Mad(\$close, 20)
Delta	差分	Delta(\$close, 1)
WMA	加权移动平均	WMA(\$close, 20)
EMA	指数移动平均	EMA(\$close, 20)
配对滚动操作符		
Cov	协方差	Cov(\$close, \$volume, 20)
Corr	相关系数	Corr(\$close, \$volume, 20)

资料来源：华泰研究

奖励设置

因子挖掘流程中涉及了较为复杂的奖励。当 RL 模型输出为 SEP token 时，认为已生成一个完整因子表达式，此时由 AlphaPool 环境进行因子评估。若因子无效，则直接给予数值为 -1 的奖励；若因子为空值或异常值、超出长度限制，给予数值为 0 的奖励；若因子位于失败缓存、效果无法入池，则给予当前 AlphaPool 最优评估指标大小的奖励，若使用 IC 评估 AlphaPool 整体效果，则为最优 IC；若因子成功入池，则给予 AlphaPool 更新后最新评估指标大小的奖励。

图表11：强化学习因子挖掘奖励设计图




资料来源：华泰研究

因子组合权重训练模型

在本文的因子挖掘流程中，单因子效果并非是唯一追求，我们希望在特定股票池中的多个因子合成后效果最优，因此前文提到的 AlphaPool 评估指标实际是指多因子合成后在股票池中的表现，可使用 IC 或 IC_IR 进行评估。对应的，在 AlphaPool 环境中可设置两种 Pool 用于因子合成，一种是 MSE Pool，使用 IC loss 优化因子组合权重；另一个种是 MeanStd Pool，使用 ICIR loss 优化因子组合权重。

图表12：AlphaPool 环境与因子权重优化流程




资料来源：华泰研究

强化学习神经网络模型

对于 RL 模型而言，我们基于 stable_baselines3_contrib 库中的 MaskablePPO 进行训练。MaskablePPO 是对传统 PPO 算法的扩展，其核心创新在于动作掩码机制，允许模型在训练和决策时动态忽略无效或非法动作，从而在复杂约束环境中实现更高效、更稳定的策略学习。在本文设置中，MaskablePPO 依赖的神经网络模型有包括 LSTM 和 Transformer。

在 RL 策略模型训练过程中，我们将截取某段样本集用于模型参数的训练迭代，这里的样本集可以理解为模型生成的动作序列（BEG、Sub、Close、Open、SEP、BEG、……）及对应状态等信息。通过类似于深度学习中 Batch 切分，我们可以打乱样本集、截取特定 Batch，进而对模型（LSTM 或 Transformer）进行更新迭代，最终获得相比于旧策略模型（参数为 θ_n ）更优的新策略模型（参数为 θ_{n+4} ）。

图表13：强化学习策略模型参数优化流程



资料来源：余昌叶（2025）《大模型算法：强化学习、微调与对齐》，华泰研究


大模型的角色

在实际进行强化学习因子挖掘时，我们会发现 RL 模型产出的相当一部分因子存在构造简单（例如 $\$volume$ ）、不合逻辑（例如 $Sub(\$volume, \$close)$ ）、符号多余（例如 $Abs(Abs(Sub(\$close, \$open)))$ ）等问题，原因在于 RL 模型并不具备语义理解能力，难以构造符合逻辑、具备一定经济学含义的因子，而这恰恰是大模型的优势所在。

因此在本文框架中，我们尝试利用大模型发挥两项功能。一项功能为构造基础池，即为 RL 模型提供一个“热身”过程，在一个较为优质的因子池中，RL 模型可能更容易挖掘出效果更进一步的因子；另一项功能是定期注入新因子，剔除劣质因子，避免 RL 模型陷入局部最优。

图表14：大模型参与强化学习因子挖掘流程图

RL模型的问题



资料来源：华泰研究

超参数设置

本文因子框架涉及较多超参数，具体参数设置及解析如下表所示。

图表15：大模型+强化学习超参数设置

参数名称	参数代码	数值	释义
AlphaPool 相关参数			
Pool 类别	-	MSE Pool, MeanStd Pool	MSE Pool 选用因子组合 IC 作为评估指标, MeanStd Pool 使用因子组合 ICIR 作为评估指标
Pool 因子容量	capacity	10	因子池容纳因子上限
Pool 基准指数	instruments	沪深 300, 中证 500, 中证 1000 基准股票池	
因子最大长度	MAX_EXPR_LENGTH	15	因子表达式最大长度, 单位为 token
因子组合权重优化相关参数			
学习率	lr	1e-3	学习率
优化器	optim	Adam	参数优化器
最大步数	max_steps	2000	迭代最大次数
早停步数	tolerance_count	200	持续多少步未低于最优 loss 即停止训练
RL 模型相关参数			
神经网络模型	features_extractor_class	LSTMSharedNet, TransformerSharedNet	用于构建策略和价值评估模型的神经网络
神经网络层数	n_layers	1	时序神经网络堆叠层数
神经网络特征维度	d_model	128	神经网络输入层和隐藏层维度
神经网络失活率	dropout	0.1	神经元随机失活比例
总训练步数	total_timesteps	10000	RL 模型总训练步数
episode 步数	n_steps	1024	actor 在每个 episode 中与环境交互的最大步数
batch 大小	batch_size	256	每个批次用于更新参数的样本量
折扣因子	gamma	0.99	用于调节近远期影响, 决定未来奖励在当前决策中的相对重要性。折扣因子越大, 算法在决策时会考虑更长远的影响; 折扣因子越小, 算法则更注重眼前利益。
熵系数	ent_coef	0.1	用于控制 PPO 算法中策略探索的能力
大模型相关参数			
大模型	-	deepseek	大模型类别
丢弃因子个数	drop_rl_n	5	每次丢弃多少个 RL 模型生成的较差因子
大模型更新间隔	llm_every_n_steps	3000	每隔多少步使用大模型更新一次因子池
样本区间参数			
训练集	train_set	20100101-20181231	用于训练模型的股票数据范围
验证集	valid_set	20190101-20201231	用于筛选模型最优时点
测试集	test_set	20210101-20251128	用于评估模型样本外效果

资料来源：华泰研究

结果

初始测试

首先，我们进行了简易条件下的初始版本测试，相比于图表 18，需要额外确认的参数如下表。这里我们使用 MSE Pool 作为交互环境，以因子组合 IC 为目标，模型方面采用 LSTM 作为 RL 策略模型，模型仅为 1 层，输入及隐藏层维度均为 128，模型结构较为简单。

图表16：初始测试超参数设置

参数名称	参数代码	数值
AlphaPool 相关参数		
Pool 类别	-	MSE Pool
Pool 基准指数	instruments	沪深 300
RL 模型相关参数		
神经网络模型	features_extractor_class	LSTMSharedNet
神经网络层数	n_layers	1
神经网络特征维度	d_model	128

资料来源：华泰研究

对于沪深 300 指增策略组合优化参数，具体设置如下表，我们设置得相对宽松，以凸显因子本身效果。


图表17：沪深 300 指增策略参数

步骤	参数	参数值
股票池	股票池	沪深 300 成分股
构建组合	基准	沪深 300
	优化目标	最大化预期收益
	组合仓位	1
	个股权重下限	0%
	个股权重上限	20%
	个股偏离权重约束	[-10%, 10%]
	行业偏离权重约束	[-20%, 20%]
	风格偏离标准差约束	[-0.2, 0.2]
	风格因子	对数流通市值
	调仓周期	每 5 个交易日
	单次调仓单边换手率上限	20%
	成分股权重约束	100%
回测	单边费率	0.0015
	交易价格	vwap
	特殊处理	停牌不买/卖出；一字板涨停不买；一字板跌停不卖；其余可交易股票重新分配权重

资料来源：华泰研究

从指增策略结果上看，自 2021 年以来总体超额可观，但在 2025 年 7 月至 9 月有较大超额收益回撤。策略年化收益率 12.32%，夏普比率 0.75，年化超额收益率 14.42%，信息比率 1.13。

图表18：初始测试沪深300指增策略效果（累计超额）



注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究

图表19：初始测试沪深300指增策略效果（业绩指标）

					Calmar 比 年化超额收 年化跟踪误			超额收益最		超额收益	年化双边
	年化收益率	年化波动率	夏普比率	最大回撤	率	益率	差	信息比率	大回撤	Calmar 比率	换手率
沪深 300 成分内增强组合	12.32%	16.34%	0.75	19.91%	0.62	14.42%	12.78%	1.13	21.36%	0.68	16.53

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究

LSTM 与 Transformer 效果对比

神经网络模型是深度强化学习模型的核心，这里我们尝试对比使用 LSTM 和 Transformer 对于最终因子挖掘效果的影响。LSTM 和 Transformer 模型的超参数选择如下表。


图表20：LSTM 与 Transformer 效果对比超参数设置

参数名称	参数代码	数值
LSTM 相关参数		
神经网络层数	n_layers	1
神经网络特征维度	d_model	128
神经网络失活率	dropout	0.1
Transformer 相关参数		
神经网络层数	n_layers	1
神经网络特征维度	d_model	16
多头自注意力头数目	n_head	8
隐藏层维度	d_ffn	128
神经网络失活率	dropout	0.1

资料来源：华泰研究

对比 LSTM 和 Transformer 对应的沪深300指增策略效果。Transformer 的效果与 LSTM 总体差别不大，但是 Transformer 更为稳定，尤其在 2025 年 7 月至 9 月超额回撤较小。从业绩指标上看，Transformer 的年化超额收益率为 16.41%，比 LSTM 的 14.42% 高约 2 个点，超额收益最大回撤 Transformer 比 LSTM 低约 4.6 个点。

图表21: LSTM 与 Transformer 的沪深 300 指增策略效果对比 (累计超额)



注: 回溯区间: 2020-12-31 至 2025-11-28; 交易费率双边 3%。

资料来源: Wind, 华泰研究

图表22: LSTM 与 Transformer 的沪深 300 指增策略效果对比 (业绩指标)


	Calmar 比 年化超额收 年化跟踪误							超额收益最		超额收益	年化双边
	年化收益率	年化波动率	夏普比率	最大回撤	率	益率	差	信息比率	大回撤	Calmar 比率	换手率
LSTM	12.32%	16.34%	0.75	19.91%	0.62	14.42%	12.78%	1.13	21.36%	0.68	16.53
Transformer	14.34%	16.07%	0.89	18.55%	0.77	16.41%	12.84%	1.28	16.71%	0.98	16.74

注: 回溯区间: 2020-12-31 至 2025-11-28; 交易费率双边 3%。

资料来源: Wind, 华泰研究

Transformer 的优势在中证 500 指增策略中体现更为明显, 回溯区间 Transformer 的年化超额收益比 LSTM 高约 6 个点。

图表23: LSTM 与 Transformer 的中证 500 指增策略效果对比 (累计超额)



注: 回溯区间: 2020-12-31 至 2025-11-28; 交易费率双边 3%。

资料来源: Wind, 华泰研究

图表24: LSTM 与 Transformer 的中证 500 指增策略效果对比 (业绩指标)

					Calmar 比 年化超额收 年化跟踪误			超额收益最		超额收益	年化双边
	年化收益率	年化波动率	夏普比率	最大回撤	率	益率	差	信息比率	大回撤	Calmar 比率	换手率
LSTM	4.47%	19.32%	0.23	27.42%	0.16	1.01%	13.97%	0.07	23.86%	0.04	16.04
Transformer	10.88%	19.95%	0.55	26.58%	0.41	7.17%	15.07%	0.48	17.78%	0.40	16.52


注: 回测区间: 2020-12-31 至 2025-11-28; 交易费率双边 3%。

资料来源: Wind, 华泰研究

IC Pool 与 ICIR Pool 效果对比

前文提到我们可以采用不同的因子池效果评估标准, 包括 IC 或者 ICIR, 这里我们对比两种评估指标最终对于策略效果的影响(使用 Transformer 作为 RL 策略模型)。在实际测试中, 从训练时长上看, 由于 ICIR 计算较 IC 更为复杂, 参数优化需要更久, 因此采用 ICIR 比 IC 训练更加耗时。从回测结果上看, 采用 ICIR 比 IC 的总体超额收益偏低, 但总体回撤更小。IC Pool 的沪深 300 指增策略年化超额收益比 ICIR 高 2.38%, 超额收益最大回撤高 3.11%。

图表25: IC Pool 与 ICIR Pool 的沪深 300 指增策略效果对比 (累计超额)



注: 回测区间: 2020-12-31 至 2025-11-28; 交易费率双边 3%。

资料来源: Wind, 华泰研究

图表26: IC Pool 与 ICIR Pool 的沪深 300 指增策略效果对比 (业绩指标)

					Calmar 比 年化超额收 年化跟踪误			超额收益最		超额收益	年化双边
	年化收益率	年化波动率	夏普比率	最大回撤	率	益率	差	信息比率	大回撤	Calmar 比率	换手率
IC Pool	14.34%	16.07%	0.89	18.55%	0.77	16.41%	12.84%	1.28	16.71%	0.98	16.74
ICIR Pool	11.98%	16.08%	0.74	21.17%	0.57	14.03%	12.70%	1.11	13.60%	1.03	16.33

注: 回测区间: 2020-12-31 至 2025-11-28; 交易费率双边 3%。

资料来源: Wind, 华泰研究


因子复杂度约束效果对比

因子复杂度本身并非是因子本身的致命问题, 但在自动化因子挖掘框架中, 模型目标往往是训练集上的 IC 等指标, 因子过于复杂往往容易导致过拟合, 然而, 如果不给予一定程度的宽松约束, 因子挖掘框架可能局限于简易构造的因子, 进而导致欠拟合。这是因子挖掘过程中值得考量的取舍问题。

我们尝试对 RL 模型产出的因子表达式进行长度限制, 以 action token 为单位, 限制其在特定范围内, 包括[3, 7]、[3, 8]、[3, 10]、[3, 12], 相比于原始设置[0, 15], 因子表达式参数空间变得更小。

从策略效果上看，当把因子复杂度设置为[3, 8]时，策略最终年化超额收益率最高，但 24 年以来超额平平；以[3, 8]为基础，因子复杂度变小或变大策略超额收益均会变差。超额收益稳定性上看，原始设置[0, 15]优于其余设置。

图表27：不同因子复杂度的沪深 300 指增策略效果对比（累计超额）



注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%

资料来源：Wind，华泰研究

图表28：不同因子复杂度的沪深 300 指增策略效果对比（业绩指标）

					Calmar 比 年化超额收 年化跟踪误			超额收益最		超额收益	年化双边
	年化收益率	年化波动率	夏普比率	最大回撤	率	益率	差	信息比率	大回撤	Calmar 比率	换手率
[0, 15]	14.34%	16.07%	0.89	18.55%	0.77	16.41%	12.84%	1.28	16.71%	0.98	16.74
[3, 7]	-4.21%	20.33%	-0.21	51.55%	-0.08	-1.56%	11.62%	-0.13	26.80%	-0.06	16.59
[3, 8]	16.11%	18.78%	0.86	17.97%	0.90	18.71%	13.23%	1.41	12.45%	1.50	16.71
[3, 10]	9.69%	16.18%	0.60	15.44%	0.63	11.60%	13.52%	0.86	21.10%	0.55	15.98
[3, 12]	4.72%	14.71%	0.32	15.27%	0.31	6.23%	14.05%	0.44	26.59%	0.23	16.41

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%

资料来源：Wind，华泰研究

奖励设置效果对比

奖励设置是 RL 环境的核心，可能会严重影响 Agent 与环境交互时的策略选择，最终显现在训练效果中。因此，针对初始版本的奖励设置，我们尝试构建不同的奖励条件，探索是否存在更优的奖励配置。


从结果上看，奖励 1-5 中未有显著稳定优于初始版本奖励的设置。奖励 3 采用了增量提升的奖励（即 $(\text{new_obj} - \text{best_obj}) * 100$ ），是唯一一个显著差于初始版本的设置。奖励 2 相比于初始版本调整了部分奖励的量纲，效果略有提升。

图表29：不同奖励设置

奖励情境	初始版本	奖励 1	奖励 2	奖励 3	奖励 4	奖励 5
因子无效	-1	-1	-1	-1	-1	-1
因子为空值或异常值	0	-0.1	0	0	0	0
因子超出最大长度限制	0	0	0	0	0	0
因子位于失败缓存	best_obj	-0.1	best_obj*10	best_obj*10	0	-0.5
因子效果无法入池	best_obj	-0.1	best_obj*10	best_obj*10	0.2	0.5
因子成功入池	new_obj	new_obj*10	new_obj*10	$(\text{new_obj} - \text{best_obj}) * 100$	new_obj*10	new_obj*10
测试效果	-	无提升	略有提升	变差	略差	总体无区别

资料来源：华泰研究

图表30：不同奖励设置下的沪深300指增策略效果对比（累计超额）



注：回测区间：2020-12-31至2025-11-28；交易费率双边3‰

资料来源：Wind，华泰研究

图表31：不同奖励设置下的沪深300指增策略效果对比（业绩指标）

	Calmar 比				年化超额收			年化跟踪误		超额收益最		超额收益	年化双边
	年化收益率	年化波动率	夏普比率	最大回撤	率	益率	差	信息比率	大回撤	Calmar 比率	换手率		
初始版本	14.34%	16.07%	0.89	18.55%	0.77	16.41%	12.84%	1.28	16.71%	0.98	16.74		
奖励1	13.04%	14.62%	0.89	16.42%	0.79	14.66%	14.04%	1.04	26.03%	0.56	16.02		
奖励2	15.02%	17.62%	0.85	23.59%	0.64	17.52%	12.12%	1.44	16.41%	1.07	16.96		
奖励3	8.57%	21.30%	0.40	29.06%	0.29	11.56%	13.26%	0.87	12.63%	0.92	16.86		
奖励4	14.14%	15.60%	0.91	13.60%	1.04	16.01%	13.60%	1.18	21.83%	0.73	16.31		
奖励5	13.99%	17.33%	0.81	19.70%	0.71	16.38%	12.38%	1.32	14.56%	1.12	16.76		

注：回测区间：2020-12-31至2025-11-28；交易费率双边3‰

资料来源：Wind，华泰研究


长训练观察

强化学习往往进行较长时程的训练，常见几十万级步数的训练设置。而前文的测试全部基于1万步训练，为对比训练步数的变化对于因子挖掘效果的影响，我们进行了一次20万步的长时程训练，进而对比不同时点因子挖掘效果的差异。

从指增策略效果上看，在5千至10万步测试中，策略超额总体效果差异并不大。当步数增加至15万和20万步时，策略超额明显变差，其中尤以15万步时效果更差，测试区间总体无超额。在5千至10万步中，只有1万步超额效果最为突出，其余步数效果相差不大。

我们还观察了训练过程中不同数据集表现随训练步数的变化，训练集和测试集IC随训练总体呈上升趋势（测量集IC总体为负可能与所选区间有关），而测试集年化超额收益率随着训练步数的增加呈下降趋势，这可能意味着模型产生了一定程度的过拟合。

图表32：长训练下不同 step 的沪深 300 指增策略效果对比（累计超额）



注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%

资料来源：Wind，华泰研究


图表33：长训练下不同 step 的沪深 300 指增策略效果对比（业绩指标）

	Calmar 比				年化超额收			年化跟踪误		超额收益最		超额收益		年化双边
	年化收益率	年化波动率	夏普比率	最大回撤	率	益率	差	信息比率	大回撤	Calmar 比率	换手率	Calmar 比率	换手率	
5120_steps	11.96%	15.13%	0.79	14.27%	0.84	13.70%	13.70%	1.00	16.79%	0.82	16.31	0.82	16.31	
10240_steps	14.34%	16.07%	0.89	18.55%	0.77	16.41%	12.84%	1.28	16.71%	0.98	16.74	0.98	16.74	
20480_steps	11.54%	16.08%	0.72	18.84%	0.61	13.55%	13.01%	1.04	22.07%	0.61	16.40	0.61	16.40	
50176_steps	11.28%	16.89%	0.67	20.82%	0.54	13.46%	12.84%	1.05	17.87%	0.75	16.52	0.75	16.52	
100352_steps	10.74%	16.70%	0.64	19.69%	0.55	12.90%	12.66%	1.02	17.74%	0.73	16.65	0.73	16.65	
150528_steps	-0.57%	24.05%	-0.02	45.41%	-0.01	2.65%	14.39%	0.18	19.76%	0.13	17.15	0.13	17.15	
200704_steps	3.40%	17.16%	0.20	22.47%	0.15	5.64%	11.53%	0.49	24.41%	0.23	16.31	0.23	16.31	

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%

资料来源：Wind，华泰研究

图表34：长训练中不同数据集表现随训练步数变化



注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%


资料来源：Wind，华泰研究

因子数量效果对比

因子数量往往被视为解释收益变量的不同维度，更多的因子数量可能意味着更多的解释维度，不过也可能存在更多的冗余维度，因此特定股票池中的因子数量也可能影响最终因子组合的效果。这里我们测试挖掘不同因子数量时的指增策略效果。

从沪深 300 指增效果上看，挖掘 5 个或 10 个因子的累计超额收益高于 20/50/100 个因子。虽然 5 个因子与 10 个因子在回测区间内超额收益相差不大，但 5 个因子的超额收益波动更大，10 个因子的超额收益曲线更为平稳。

图表35：不同因子数量下的沪深 300 指增策略效果对比（累计超额）



注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究

图表36：不同因子数量下的沪深 300 指增策略效果对比（业绩指标）

	年化收益率	年化波动率	夏普比率	最大回撤	Calmar 比			信息比率	超额收益最		超额收益	年化双边
					率	益率	差		大回撤	Calmar 比率		
5 个因子	14.30%	14.78%	0.97	13.25%	1.08	15.98%	13.94%	1.15	19.00%	0.84	15.64	
10 个因子	14.34%	16.07%	0.89	18.55%	0.77	16.41%	12.84%	1.28	16.71%	0.98	16.74	
20 个因子	6.25%	16.00%	0.39	20.71%	0.30	8.18%	12.79%	0.64	18.26%	0.45	16.28	
50 个因子	4.75%	17.93%	0.26	28.56%	0.17	7.18%	11.28%	0.64	18.64%	0.39	16.62	
100 个因子	7.71%	21.49%	0.36	41.33%	0.19	10.82%	12.48%	0.87	14.32%	0.76	17.01	

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究


大模型增强效果

如前所述，大模型可以以增强角色融入强化学习因子挖掘流程中，一方面提供初始因子池，快速启动挖掘流程；另一方面定期“去弱留强”，为因子池注入新因子，避免陷入具备最优。我们尝试在沪深 300 和中证 500 中验证大模型可能存在的增强效果。

从对比结果中，相比于仅用强化学习驱动的沪深 300 指增策略，融入大模型后，策略年化超额出现明显提升，由 16.41% 提升至 17.85%，夏普比率从 0.89 提升至 0.97，但超额收益最大回撤有所提升，从 16.71% 升至 17.28%。

中证 500 指增策略表现类似，大模型加入强化学习因子挖掘流程后，年化超额收益率提升由 7.17% 提升至 9.78%，夏普比率从 0.55 提升至 0.69，但超额收益最大回撤同样变大，从 17.78% 变大至 18.45%。

图表37：RL 与 RL+大模型的沪深 300 指增策略效果对比（累计超额）



注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究

图表38：RL 与 RL+大模型的沪深 300 指增策略效果对比（业绩指标）

					Calmar 比 年化超额收 年化跟踪误			超额收益最		超额收益		年化双边
	年化收益率	年化波动率	夏普比率	最大回撤	率	益率	差	信息比率	大回撤	Calmar 比率		换手率
RL	14.34%	16.07%	0.89	18.55%	0.77	16.41%	12.84%	1.28	16.71%	0.98		16.74
RL+大模型	15.60%	16.11%	0.97	15.19%	1.03	17.85%	11.87%	1.50	17.28%	1.03		16.60

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究

图表39：RL 的沪深 300 指增策略逐月超额收益

	1月	2月	3月	4月	5月	6月	7月	8月	9月	10月	11月	12月	年超额收益
2021 年	-1.9%	8.6%	9.1%	-5.3%	-2.5%	1.8%	10.7%	4.7%	6.9%	0.5%	-1.7%	4.1%	34.8%
2022 年	5.1%	1.1%	3.5%	0.3%	0.8%	-4.4%	0.8%	3.2%	3.5%	4.4%	0.8%	-0.6%	19.9%
2023 年	-3.5%	2.4%	2.8%	6.5%	5.1%	-3.2%	0.5%	-1.4%	0.9%	-0.5%	0.8%	-0.6%	11.2%
2024 年	6.3%	-3.0%	0.3%	0.6%	2.3%	3.6%	3.6%	-0.8%	-2.0%	4.5%	-3.6%	2.2%	10.3%
2025 年	-0.3%	3.7%	-0.3%	2.3%	1.4%	0.7%	1.5%	-7.0%	-6.8%	6.0%	1.0%		2.6%

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究


图表40：RL+大模型的沪深 300 指增策略逐月超额收益

	1月	2月	3月	4月	5月	6月	7月	8月	9月	10月	11月	12月	年超额收益
2021 年	-2.8%	3.8%	10.7%	0.7%	-3.0%	0.7%	1.1%	-1.6%	7.2%	-0.4%	-2.1%	1.7%	14.4%
2022 年	4.8%	0.9%	8.7%	1.7%	1.5%	1.0%	-4.3%	2.7%	6.5%	6.5%	2.8%	-0.2%	37.9%
2023 年	-1.2%	1.1%	2.6%	6.8%	4.4%	-2.9%	-2.1%	4.0%	1.3%	-1.3%	3.3%	-1.2%	17.2%
2024 年	9.0%	-2.4%	-0.2%	3.0%	3.1%	3.9%	5.0%	0.9%	0.3%	0.2%	-0.5%	2.7%	28.9%
2025 年	0.8%	-0.4%	-0.4%	2.9%	1.6%	-0.3%	-2.0%	-7.0%	-5.3%	1.1%	1.3%		-9.1%

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究

图表41：RL 与 RL+大模型的中证 500 指增策略效果对比（累计超额）



注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究

图表42：RL 与 RL+大模型的中证 500 指增策略效果对比（业绩指标）

					Calmar 比			年化超额收	年化跟踪误	超额收益最		超额收益	年化双边
	年化收益率	年化波动率	夏普比率	最大回撤	率	益率	差	信息比率	大回撤	Calmar 比率		换手率	
RL	10.88%	19.95%	0.55	26.58%	0.41	7.17%	15.07%	0.48	17.78%		0.40	16.52	
RL+大模型	13.58%	19.68%	0.69	24.03%	0.56	9.78%	14.66%	0.67	18.45%		0.53	16.48	

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究

图表43：RL 的中证 500 指增策略逐月超额收益

	1月	2月	3月	4月	5月	6月	7月	8月	9月	10月	11月	12月	年超额收益
2021 年	-6.4%	4.1%	8.3%	-5.3%	-3.7%	-1.7%	-5.5%	1.1%	24.2%	-8.9%	-4.3%	5.2%	8.0%
2022 年	4.4%	-1.3%	7.5%	5.0%	-2.1%	-5.4%	3.1%	2.7%	0.5%	-6.4%	4.2%	1.6%	14.3%
2023 年	-2.5%	1.1%	-1.7%	3.6%	0.3%	1.6%	6.0%	0.4%	1.2%	0.3%	-2.9%	-2.4%	5.7%
2024 年	6.6%	-3.1%	-3.3%	1.0%	0.8%	-2.1%	3.1%	1.3%	-3.3%	5.5%	-2.2%	4.1%	4.3%
2025 年	-1.9%	1.4%	3.1%	1.1%	4.4%	-3.4%	2.4%	-7.7%	-5.0%	4.7%	2.6%		1.4%

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究

图表44：RL+大模型的中证 500 指增策略逐月超额收益

	1月	2月	3月	4月	5月	6月	7月	8月	9月	10月	11月	12月	年超额收益
2021 年	-3.0%	5.4%	5.0%	-2.4%	-3.8%	2.4%	-4.8%	0.3%	10.6%	-7.1%	-4.3%	2.4%	2.6%
2022 年	4.4%	1.0%	5.0%	3.9%	1.7%	-2.5%	0.5%	2.0%	0.5%	-5.5%	2.9%	4.8%	23.0%
2023 年	-2.6%	1.4%	1.5%	4.1%	-0.5%	1.3%	9.9%	-0.5%	0.3%	-0.7%	0.4%	-2.1%	15.7%
2024 年	7.5%	-3.4%	-2.5%	0.8%	0.2%	-2.2%	4.9%	5.1%	1.3%	0.5%	-0.1%	1.6%	11.2%
2025 年	-2.2%	1.7%	2.5%	3.4%	3.3%	-2.2%	0.4%	-8.9%	-6.0%	4.6%	1.2%		-3.9%

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。


资料来源：Wind，华泰研究

因子泛化性测试

前文沪深 300 或中证 500 指增组合使用的因子均在各自股票池中训练得来，为了验证因子的泛化性，我们尝试将沪深 300 的因子组合（大模型增强后）应用于中证 500 指增策略中，将中证 500 的因子组合（大模型增强后）应用于沪深 300 指增策略中，观察因子是否仍能带来显著超额收益。

从结果上看，沪深 300 因子组合应用于中证 500 指增策略效果依旧稳定，年化超额收益率 17.85%，信息比率 1.50；中证 500 因子组合应用于沪深 300 指增策略效果也较为亮眼，年化超额收益率 18.52%，信息比率 1.46。总体显示各因子组合具有一定程度泛化性。

图表45：沪深300因子组合应用于中证500指增策略效果



注：回溯区间：2020-12-31至2025-11-28；交易费率双边3%

资料来源：Wind，华泰研究

图表46：沪深300因子组合应用于中证500指增策略效果（业绩指标）

					Calmar 比 年化超额收 年化跟踪误			超额收益最		超额收益	年化双边
	年化收益率	年化波动率	夏普比率	最大回撤	率	益率	差	信息比率	大回撤	Calmar 比率	换手率
中证 500 成分内增强组合	15.60%	16.11%	0.97	15.19%	1.03	17.85%	11.87%	1.50	17.28%	1.03	16.60

注：回溯区间：2020-12-31至2025-11-28；交易费率双边3%

资料来源：Wind，华泰研究


图表47：沪深300因子组合应用于中证500指增策略逐月超额收益

	1月	2月	3月	4月	5月	6月	7月	8月	9月	10月	11月	12月	年超额收益
2021年	-2.8%	3.8%	10.7%	0.7%	-3.0%	0.7%	1.1%	-1.6%	7.2%	-0.4%	-2.1%	1.7%	14.4%
2022年	4.8%	0.9%	8.7%	1.7%	1.5%	1.0%	-4.3%	2.7%	6.5%	6.5%	2.8%	-0.2%	37.9%
2023年	-1.2%	1.1%	2.6%	6.8%	4.4%	-2.9%	-2.1%	4.0%	1.3%	-1.3%	3.3%	-1.2%	17.2%
2024年	9.0%	-2.4%	-0.2%	3.0%	3.1%	3.9%	5.0%	0.9%	0.3%	0.2%	-0.5%	2.7%	28.9%
2025年	0.8%	-0.4%	-0.4%	2.9%	1.6%	-0.3%	-2.0%	-7.0%	-5.3%	1.1%	1.3%		-9.1%

注：回溯区间：2020-12-31至2025-11-28；交易费率双边3%

资料来源：Wind，华泰研究

图表48：中证500因子组合应用于沪深300指增策略效果



注：回溯区间：2020-12-31至2025-11-28；交易费率双边3%

资料来源：Wind，华泰研究

图表49：中证 500 因子组合应用于沪深 300 指增策略效果（业绩指标）

	Calmar 比				年化超额收			年化跟踪误		超额收益最		超额收益		年化双边
	率	益率	差	信息比率	大回撤	Calmar 比率	换手率	率	益率	差	信息比率	大回撤	Calmar 比率	换手率
沪深 300 成分内增强组合	16.42%	15.86%	1.04	17.54%	0.94	18.52%	12.67%	1.46	17.65%	1.05	16.51			

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%

资料来源：Wind，华泰研究

图表50：中证 500 因子组合应用于沪深 300 指增策略逐月超额收益

	1月	2月	3月	4月	5月	6月	7月	8月	9月	10月	11月	12月	年超额收益
2021 年	-3.1%	4.1%	11.7%	-3.4%	-3.2%	1.3%	2.1%	11.6%	6.7%	-0.4%	-2.9%	0.1%	20.5%
2022 年	2.4%	-0.9%	4.5%	4.0%	-0.5%	-0.2%	-0.7%	7.1%	2.6%	3.1%	2.9%	-0.6%	27.5%
2023 年	-6.7%	3.3%	0.3%	4.1%	1.7%	-1.2%	1.2%	1.0%	3.2%	1.6%	0.1%	0.9%	10.2%
2024 年	7.0%	-2.0%	1.4%	3.5%	4.5%	4.4%	2.5%	2.6%	2.4%	2.5%	-0.2%	5.7%	39.9%
2025 年	-1.7%	-2.3%	1.9%	3.3%	3.0%	-1.5%	-1.1%	-9.3%	-4.6%	5.5%	1.1%		-7.5%

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%

资料来源：Wind，华泰研究

因子评估与因子相关性


为了进一步评估大模型+强化学习挖掘因子的特性，我们进一步对其累计 IC、分层收益及相关性进行分析。从累计 IC 上看，沪深 300 因子组合与中证 500 因子组合均相对稳定，只有 2021 年 3-6 月与 2025 年 6-9 月出现较为明显回撤。

从分层收益上看，两个因子组合分层均相对单调，沪深 300 因子组合多空分层相对均衡，中证 500 因子组合空头分层效应更为突出，两个因子组合近期部分分层超额收益有所回撤。

从因子相关性上看，无论沪深 300 还是中证 500 因子组合在估值（Book to Price）上均有较高相关性，中证 500 因子组合在市值（Size）上的暴露明显偏负，显现出一定程度的小盘价值风格暴露。


此外，我们对比两个因子组合与同样基于量价数据的 GRU 因子（《人工智能 72：基于全频段量价特征的选股模型》20231208）间的相关性，发现二者间的相关性周期性波动，均值都在 0.2 左右，相对偏低，近几年相关性中枢相对上移，表明二者对于量价信息的捕捉存在差异之处。

图表51：沪深 300 因子组合累计 IC 与 RankIC



资料来源：Wind，华泰研究

图表52：沪深 300 因子组合累计分层超额收益



注：分层超额收益基准为等权组合


资料来源：Wind，华泰研究

图表53：沪深 300 因子组合与 Barra 风险因子相关性

Beta	Book to Price	Dividend Yield	Earning Yield	Earnings Quality	Earnings Variability	Growth	Investment Quality	Leverage	Liquidity	Long-Term Reversal	Momentum	Non-li near Size	Profitab ility	Residual Volatility	Size
-0.11	0.35	0.16	0.11	0.03	0.00	0.02	-0.03	0.08	-0.46	0.07	-0.28	-0.08	-0.08	-0.11	-0.06


资料来源：Wind，华泰研究

图表54：沪深300因子组合与GRU量价因子时序相关性




资料来源：Wind，华泰研究

图表55：中证500因子组合累计IC与RankIC



资料来源：Wind，华泰研究

图表56：中证500因子组合累计分层超额收益



注：分层超额收益基准为等权组合


资料来源：Wind，华泰研究

图表57：中证500因子组合与Barra风险因子相关性

Beta	Book to Price	Dividend Yield	Earning Yield	Earnings Quality	Earnings Variability	Growth	Investment Quality	Leverage	Liquidity	Long-Term Reversal	Momentum	Non-li near Size	Profitab ility	Residual Volatility	Size
-0.04	0.33	0.17	0.12	0.01	-0.01	0.00	-0.02	0.10	-0.38	0.01	-0.22	-0.02	-0.05	-0.07	-0.34

资料来源：Wind，华泰研究

图表58：中证 500 因子组合与 GRU 量价因子时序相关性



资料来源：Wind，华泰研究

指增策略收紧约束效果

前文指增策略测试中对于组合优化的约束相对宽松，持仓个股权重会超过 10%，为了贴近实际指增策略设置，我们设置了如下表中的约束，以检查策略效果是否稳定。


图表59：指增策略参数（收紧约束）

步骤	参数	参数值
股票池	股票池	沪深 300 成分股/中证 500 成分股
构建组合	基准	沪深 300/中证 500
	优化目标	最大化预期收益
	组合仓位	1
	个股权重下限	0%
	个股权重上限	6%
	个股偏离权重约束	[-5%, 5%]
	行业偏离权重约束	[-10%, 10%]
	风格偏离标准差约束	[-0.2, 0.2]
	风格因子	对数流通市值
	调仓周期	每 5 个交易日
	单次调仓单边换手率上限	20%
	成分股权重约束	100%

资料来源：华泰研究

从效果上看，收紧约束后，沪深 300 与中证 500 指增效果仍相对突出，沪深 300 年化超额收益率 11.00%，信息比率 1.03；中证 500 年化超额收益率 6.59%，信息比率 0.50。但相比于未收紧约束前，超额收益与信息比率均有所下降，超额收益最大回撤也更大。

图表60：收紧约束下沪深300指增策略效果



注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究


图表61：收紧约束下沪深300指增策略效果（业绩指标）

	年化收益率	年化波动率	夏普比率	最大回撤	Calmar 比			信息比率	超额收益最		年化双边
					率	益率	差		大回撤	Calmar 比率	换手率
沪深300 成分内增强组合	8.88%	15.25%	0.58	18.65%	0.48	11.00%	10.63%	1.03	20.25%	0.54	16.75

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究

图表62：收紧约束下中证500指增策略效果



注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究

图表63：收紧约束下中证500指增策略效果（业绩指标）

	年化收益率	年化波动率	夏普比率	最大回撤	Calmar 比			信息比率	超额收益最		年化双边
					率	益率	差		大回撤	Calmar 比率	换手率
中证500 成分内增强组合	10.25%	18.62%	0.55	23.61%	0.43	6.59%	13.10%	0.50	18.09%	0.36	16.11

注：回测区间：2020-12-31 至 2025-11-28；交易费率双边 3%。

资料来源：Wind，华泰研究

总结

本文是对大模型+强化学习应用于因子挖掘领域的深入探索，显示出强化学习挖掘因子的可行性，以及大模型对于强化学习因子挖掘的增强作用。强化学习离不开因子表达式的 Token 化序列建模，Token 化后的因子表达式建模，便转化为 PPO 等强化学习算法擅于模拟的序列决策问题。换句话说，一个 Token 可以代表一个动作，一个表达式可以代表一个决策序列、一个因子的预测能力（IC、IR、收益改善）可以代表奖励，强化学习的训练过程就是自主发现优秀因子表达式的过程。从结果上看，基于强化学习挖掘出的因子组合在沪深 300 指增策略表现优异，回测区间内年化超额收益率可达 16.41%；在中证 500 指增策略中表现同样较好，回测区间内年化超额收益率达 7.17%。

然而，在实际进行强化学习因子挖掘时，我们会发现强化学习模型产出的相当一部分因子存在构造简单、不合逻辑、符号多余等问题。原因可能是强化学习模型缺乏语义理解能力，难以构造符合逻辑、具备一定经济学含义的因子，而这恰恰是大模型的优势所在。因此我们尝试利用大模型提供初始因子池，同时定期更新因子池，剔除相对差的因子，加入可能表现更好的因子，使得因子池成为“活水”池。结果显示，大模型增强后的沪深 300 组合与中证 500 组合年化超额收益率能够提升 1-2% 的超额。

在对本文因子框架进行测试时，我们对比了诸多可能影响因子挖掘效果的因素，包括强化学习策略模型类别、环境评估指标、因子复杂度约束、奖励设置、训练时程、因子数量等。其中或多或少能够反映出一些可能的结论，但由于资源所限，我们并不能把每项因素的所有可能取值测试完全，所以尚未测试的参数空间是否存在更优效应尚未可知。

总结而言，本文尝试进行新颖的大模型+强化学习结合的因子挖掘方案，并基于实际测试展示出强化学习的因子挖掘效果、以及大模型带来的增益效果，不过仍有较多角度未能进行详尽测试、探索亦有未尽之处，大模型+强化学习的量化投资应用仍颇具潜力。

参考文献

- Bilokon, P., & Qiu, Y. (2023). Transformers versus LSTMs for electronic trading. *arXiv preprint arXiv:2309.11400*.
- Shi, H., Song, W., Zhang, X., Shi, J., Luo, C., Ao, X., ... & Seco, L. A. (2025, April). Alphaforge: A framework to mine and dynamically combine formulaic alpha factors. In *Proceedings of the AAAI Conference on Artificial Intelligence* (Vol. 39, No. 12, pp. 12524-12532).
- Xu F, Yin Y, Zhang X, Liu T, Jiang S, Zhang Z. α^2 : Discovering Logical Formulaic Alphas using Deep Reinforcement Learning. *arXiv preprint arXiv:2406.16505*. 2024 Jun 24.
- Yu, S., Xue, H., Ao, X., Pan, F., He, J., Tu, D., & He, Q. (2023, August). Generating synergistic formulaic alpha collections via reinforcement learning. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining* (pp. 5476-5486).
- Zhu, Z., & Zhu, K. AlphaQCM: Alpha Discovery in Finance with Distributional Reinforcement Learning. In *Forty-second International Conference on Machine Learning*.
- 余昌叶. 大模型算法：强化学习、微调与对齐 [M]. 北京：电子工业出版社，2025.
<https://github.com/changyeyu/LLM-RL-Visualized>

风险提示

大模型是海量数据训练获得的产物，输出准确性及稳定性可能存在风险；不同大模型效果存在差异，需谨慎选择；非本地大模型处理敏感数据或有信息泄露风险；通过强化学习模型构建选股策略是历史经验的总结，存在失效的可能。强化学习模型可解释程度较低，使用须谨慎。

免责声明

分析师声明

本人，沈洋、何康，兹证明本报告所表达的观点准确地反映了分析师对标的证券或发行人的个人意见；彼以往、现在或未来并无就其研究报告所提供的具体建议或所表达的意见直接或间接收取任何报酬。请注意，标*的人员并非香港证券及期货事务监察委员会的注册持牌人，不可在香港从事受监管活动。

一般声明及披露

本报告由华泰证券股份有限公司或其关联机构制作，华泰证券股份有限公司和其关联机构统称为“华泰证券”（华泰证券股份有限公司已具备中国证监会批准的证券投资咨询业务资格）。本报告所载资料是仅供接收人的严格保密资料。本报告仅供华泰证券及其客户和其关联机构使用。华泰证券不因接收人收到本报告而视其为客户。

本报告基于华泰证券认为可靠的、已公开的信息编制，但华泰证券对该等信息的准确性及完整性不作任何保证。

本报告所载的意见、评估及预测仅反映报告发布当日的观点和判断。在不同时期，华泰证券可能会发出与本报告所载意见、评估及预测不一致的研究报告。同时，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。以往表现并不能指引未来，未来回报并不能得到保证，并存在损失本金的可能。华泰证券不保证本报告所含信息保持在最新状态。华泰证券对本报所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

华泰证券（华泰证券（美国）有限公司除外）不是 FINRA 的注册会员，其研究分析师亦没有注册为 FINRA 的研究分析师/不具有 FINRA 分析师的注册资格。

华泰证券力求报告内容客观、公正，但本报告所载的观点、结论和建议仅供参考，不构成购买或出售所述证券的要约或招揽。该等观点、建议并未考虑到个别投资者的具体投资目的、财务状况以及特定需求，在任何时候均不构成对客户私人投资建议。投资者应当充分考虑自身特定状况，并完整理解和使用本报告内容，不应视本报告为做出投资决策的唯一因素。对依据或者使用本报告所造成的一切后果，华泰证券及作者均不承担任何法律责任。任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现，过往的业绩表现不应作为日后回报的预示。华泰证券不承诺也不保证任何预示的回报会得以实现，分析中所做的预测可能是基于相应的假设，任何假设的变化可能会显著影响所预测的回报。

华泰证券及作者在自身所知情的范围内，与本报告所指的证券或投资标的不存在法律禁止的利害关系。在法律许可的情况下，华泰证券可能会持有报告中提到的公司所发行的证券头寸并进行交易，为该公司提供投资银行、财务顾问或者金融产品等相关服务或向该公司招揽业务。

华泰证券的销售人员、交易人员或其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。华泰证券没有将此意见及建议向报告所有接收者进行更新的义务。华泰证券的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。投资者应当考虑到华泰证券及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。投资者请勿将本报告视为投资或其他决定的唯一信赖依据。有关该方面的具体披露请参照本报告尾部。

本报告并非意图发送、发布给在当地法律或监管规则下不允许向其发送、发布的机构或人员，也并非意图发送、发布给因可得到、使用本报告的行为而使华泰证券违反或受制于当地法律或监管规则的机构或人员。

本报告版权仅为华泰证券所有。未经华泰证券书面许可，任何机构或个人不得以翻版、复制、发表、引用或再次分发他人（无论整份或部分）等任何形式侵犯华泰证券版权。如征得华泰证券同意进行引用、刊发的，需在允许的范围内使用，并需在使用前获取独立的法律意见，以确定该引用、刊发符合当地适用法规的要求，同时注明出处为“华泰证券研究所”，且不得对本报告进行任何有悖原意的引用、删节和修改。华泰证券保留追究相关责任的权利。所有本报告中使用的商标、服务标记及标记均为华泰证券的商标、服务标记及标记。

中国香港

本报告由华泰证券股份有限公司或其关联机构制作，在香港由华泰金融控股（香港）有限公司向符合《证券及期货条例》及其附属法律规定的机构投资者和专业投资者的客户进行分发。华泰金融控股（香港）有限公司受香港证券及期货事务监察委员会监管，是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。在香港获得本报告的人员若有任何有关本报告的问题，请与华泰金融控股（香港）有限公司联系。

香港-重要监管披露

- 华泰金融控股（香港）有限公司的雇员或其关联人士没有担任本报告中提及的公司或发行人的高级人员。
- 有关重要的披露信息，请参华泰金融控股（香港）有限公司的网页 https://www.htsc.com.hk/stock_disclosure 其他信息请参见下方 “美国-重要监管披露”。

美国

在美国本报告由华泰证券（美国）有限公司向符合美国监管规定的机构投资者进行发表与分发。华泰证券（美国）有限公司是美国注册经纪商和美国金融业监管局（FINRA）的注册会员。对于其在美国分发的研究报告，华泰证券（美国）有限公司根据《1934年证券交易法》（修订版）第15a-6条规定以及美国证券交易委员会人员解释，对本研究报告内容负责。华泰证券（美国）有限公司联营公司的分析师不具有美国金融监管（FINRA）分析师的注册资格，可能不属于华泰证券（美国）有限公司的关联人员，因此可能不受 FINRA 关于分析师与标的公司沟通、公开露面和所持交易证券的限制。华泰证券（美国）有限公司是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。任何直接从华泰证券（美国）有限公司收到此报告并希望就本报告所述任何证券进行交易的人士，应通过华泰证券（美国）有限公司进行交易。

美国-重要监管披露

- 分析师沈洋、何康本人及相关人士并不担任本报告所提及的标的证券或发行人的高级人员、董事或顾问。分析师及相关人士与本报告所提及的标的证券或发行人并无任何相关财务利益。本披露中所提及的“相关人士”包括 FINRA 定义下分析师的家庭成员。分析师根据华泰证券的整体收入和盈利能力获得薪酬，包括源自公司投资银行业务的收入。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或不时会以自身或代理形式向客户出售及购买华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或其高级管理层、董事和雇员可能会持有本报告中所提到的任何证券（或任何相关投资）头寸，并可能不时进行增持或减持该证券（或投资）。因此，投资者应该意识到可能存在利益冲突。

新加坡

华泰证券（新加坡）有限公司持有新加坡金融管理局颁发的资本市场服务许可证，可从事资本市场产品交易，包括证券、集体投资计划中的单位、交易所交易的衍生品合约和场外衍生品合约，并且是《财务顾问法》规定的豁免财务顾问，就投资产品向他人提供建议，包括发布或公布研究分析或研究报告。华泰证券（新加坡）有限公司可能会根据《财务顾问条例》第32C条的规定分发其在华泰证券内的外国附属公司各自制作的信息/研究。本报告仅供认可投资者、专家投资者或机构投资者使用，华泰证券（新加坡）有限公司不对本报告内容承担法律责任。如果您是非预期接收者，请您立即通知并直接将本报告返回给华泰证券（新加坡）有限公司。本报告的新加坡接收者应联系您的华泰证券（新加坡）有限公司关系经理或客户主管，了解来自或与所分发的信息相关的事宜。

评级说明

投资评级基于分析师对报告发布日后6至12个月内行业或公司回报潜力（含此期间的股息回报）相对基准表现的预期（A股市场基准为沪深300指数，香港市场基准为恒生指数，美国市场基准为标普500指数，台湾市场基准为台湾加权指数，日本市场基准为日经225指数，新加坡市场基准为海峡时报指数，韩国市场基准为韩国有价证券指数，英国市场基准为富时100指数，德国市场基准为DAX指数），具体如下：

行业评级

增持：预计行业股票指数超越基准

中性：预计行业股票指数基本与基准持平

减持：预计行业股票指数明显弱于基准

公司评级

买入：预计股价超越基准15%以上

增持：预计股价超越基准5%~15%

持有：预计股价相对基准波动在-15%~5%之间

卖出：预计股价弱于基准15%以上

暂停评级：已暂停评级、目标价及预测，以遵守适用法规及/或公司政策

无评级：股票不在常规研究覆盖范围内。投资者不应期待华泰提供该等证券及/或公司相关的持续或补充信息

法律实体披露

中国: 华泰证券股份有限公司具有中国证监会核准的“证券投资咨询”业务资格, 经营许可证编号为: 91320000704041011J

香港: 华泰金融控股(香港)有限公司具有香港证监会核准的“就证券提供意见”业务资格, 经营许可证编号为: AOK809

美国: 华泰证券(美国)有限公司为美国金融业监管局(FINRA)成员, 具有在美国开展经纪交易商业业务的资格, 经营业务许可编号为: CRD#:298809/SEC#:8-70231

新加坡: 华泰证券(新加坡)有限公司具有新加坡金融管理局颁发的资本市场服务许可证, 并且是豁免财务顾问, 经营许可证编号为: 202233398E

华泰证券股份有限公司**南京**

南京市建邺区江东中路228号华泰证券广场1号楼/邮政编码: 210019

电话: 86 25 83389999/传真: 86 25 83387521

电子邮件: ht-rd@htsc.com

深圳

深圳市福田区益田路5999号基金大厦10楼/邮政编码: 518017

电话: 86 755 82493932/传真: 86 755 82492062

电子邮件: ht-rd@htsc.com

北京

北京市西城区太平桥大街丰盛胡同28号太平洋保险大厦A座18层/

邮政编码: 100032

电话: 86 10 63211166/传真: 86 10 63211275

电子邮件: ht-rd@htsc.com

上海

上海市浦东新区东方路18号保利广场E栋23楼/邮政编码: 200120

电话: 86 21 28972098/传真: 86 21 28972068

电子邮件: ht-rd@htsc.com

华泰金融控股(香港)有限公司

香港中环皇后大道中99号中环中心53楼

电话: +852-3658-6000/传真: +852-2567-6123

电子邮件: research@htsc.com

http://www.htsc.com.hk

华泰证券(美国)有限公司

美国纽约公园大道280号21楼东(纽约10017)

电话: +212-763-8160/传真: +917-725-9702

电子邮件: Huatai@htsc-us.com

http://www.htsc-us.com

华泰证券(新加坡)有限公司

滨海湾金融中心1号大厦, #08-02, 新加坡 018981

电话: +65 68603600

传真: +65 65091183

https://www.htsc.com.sg

©版权所有2025年华泰证券股份有限公司